

Documentación final en desarrollo

Proyecto: ENIGH, ingresos y territorio en México

Años: 2018, 2020, 2022 y 2024

Estado: documento vivo de trabajo para tesina

Este documento consolida las decisiones metodológicas ya tomadas en las revisiones 1 a 4, el estado del arte geográfico y los notebooks 04 a 08. Los archivos históricos en [reports/](#) se conservan como bitácora; de aquí en adelante este archivo funciona como referencia principal del proyecto.

Resumen del proyecto

El proyecto usa microdatos de la Encuesta Nacional de Ingresos y Gastos de los Hogares (ENIGH) para estudiar la distribución del ingreso en México entre 2018 y 2024. El énfasis actual está en construir bases analíticas interpretables, reproducibles y adecuadas para una tesina escolar, más que en montar una arquitectura operativa compleja.

La estrategia seguida ha sido:

- homologar variables comparables entre años;
- validar tipos, llaves y relaciones entre tablas;
- incorporar geografía segura a nivel entidad y municipio;
- decodificar variables categóricas prioritarias;
- construir bases analíticas de personas y hogares;
- documentar faltantes, ceros y universos aplicables;
- iniciar análisis territorial descriptivo con regiones Banxico, entidad, tamaño de localidad y estrato socioeconómico.

Pregunta de investigación

La pregunta refinada del proyecto es:

¿Cómo cambian los determinantes individuales, laborales, familiares y territoriales del ingreso en México entre 2018 y 2024, y en qué medida estas asociaciones son heterogéneas entre regiones, entidades, niveles de urbanización y estratos socioeconómicos?

Esta formulación evita limitar la tesina a comparar promedios o Gini por región, porque Banco de México ya tiene antecedentes directos sobre desigualdad regional con ENIGH.

Objetivo general

Analizar la relación entre características personales, laborales, del hogar y territoriales con el ingreso en México, usando microdatos ENIGH 2018, 2020, 2022 y 2024, con una base metodológica reproducible y documentada.

Objetivos específicos

- Construir bases analíticas comparables a nivel persona y hogar.

- Verificar que las variables centrales estén homologadas y decodificadas de forma comparable.
- Documentar faltantes, ceros y universos de aplicación antes de modelar.
- Explorar diferencias de ingreso por región Banxico, entidad, tamaño de localidad y estrato socioeconómico.
- Separar análisis de niveles de ingreso, desigualdad interna y brechas territoriales.
- Mantener explícitas las limitaciones de inferencia de la ENIGH.

Hipótesis de trabajo

Las hipótesis actuales son de asociación, no de causalidad:

- La asociación entre educación e ingreso cambia entre regiones Banxico.
- El estrato socioeconómico oficial de INEGI aporta información adicional sobre la distribución del ingreso.
- Las características laborales se asocian con ingresos de manera distinta entre contextos urbanos y rurales.
- Las asociaciones entre características individuales/laborales e ingreso no son completamente estables entre 2018 y 2024.
- Las variables territoriales pueden enriquecer el análisis, siempre que no se interprete el municipio como dominio representativo automático.

Fuente de datos

La fuente es ENIGH para los levantamientos 2018, 2020, 2022 y 2024, almacenados localmente en `data/raw/EINGH/`.

Los cuatro levantamientos se concatenan como cortes transversales independientes. No son panel: un hogar observado en 2018 y uno observado en 2024 no representan seguimiento de la misma unidad.

Estructura original de ENIGH y relaciones

El notebook `04_relaciones_entre_bases.ipynb` validó la estructura relacional:

Tabla	Nivel	Llave	Relación
<code>viviendas</code>	vivienda	<code>folioviv</code>	1:N hogares
<code>hogares</code>	hogar	<code>folioviv + foliohog</code>	N:1 vivienda; 1:N población
<code>concentradohogar</code>	hogar agregado	<code>folioviv + foliohog</code>	1:1 hogares
<code>poblacion</code>	persona	<code>folioviv + foliohog + numren</code>	N:1 hogar
<code>trabajos</code>	trabajo	<code>folioviv + foliohog + numren + id_trabajo</code>	N:1 persona
<code>ingresos</code>	persona-clave ingreso	<code>folioviv + foliohog + numren + clave</code>	N:1 persona

Todas las llaves propuestas tuvieron 0 duplicados por año y las unidades hijas tuvieron padre en las relaciones revisadas.

Una regla metodológica importante es no hacer merges directos `poblacion -> trabajos -> ingresos` sin agregación previa, porque `trabajos` e `ingresos` son tablas 1:N respecto a persona.

Bases analíticas o marts

Se construyeron dos bases analíticas en `data/interim/revision_4/`:

Base	Archivo	Unidad	Filas	Columnas	Llave
Personas	<code>mart_persona_2018_2024.csv.gz</code>	persona-año	1,203,231	140	<code>anio + folioviv + foliohog + numren</code>
Hogares	<code>mart_hogar_2018_2024.csv.gz</code>	hogar-año	345,169	92	<code>anio + folioviv + foliohog</code>

`mart` significa base analítica preparada para análisis a una granularidad específica. En la documentación visible se usa también "base analítica de personas" y "base analítica de hogares".

Limpieza y homologación

Los avances principales fueron:

- homologación de columnas comparables entre 2018, 2020, 2022 y 2024;
- corrección de inconsistencias específicas de 2024;
- limpieza mínima de cadenas vacías y espacios;
- validación de tipos y eliminación de artefactos decimales en variables categóricas;
- incorporación de `region_banxico` y alias `factor`;
- normalización de `est_socio_desc` por código;
- corrección de `asis_esc_desc` por código oficial `asis_esc`.

No se modificó `data/raw/`. Las correcciones viven en las bases intermedias y en los notebooks que permiten reproducirlas.

Variables categóricas

El notebook 03 y la revisión 3 documentan la decodificación:

- variables con mapping extraído: 431;
- filas código-etiqueta extraídas: 4,406;
- variables decodificadas: 263;
- columnas `_desc` creadas: 263.

La prueba inicial confirmó mapeos para variables prioritarias como sexo, habla indígena, etnia, alfabetismo, asistencia escolar, nivel aprobado, estado conyugal, parentesco y residencia. Algunas variables de años de adquisición o conteos del hogar quedaron para revisión manual porque no conviene tratarlas como categóricas sustantivas sin validar su universo.

Geografía

La geografía se incorporó mediante `ubica_geo`, construida como clave entidad + municipio. Con esta llave se obtuvo cobertura de 100% en los cruces con `concentradohogar` y `viviendas`, incorporando:

- `cve_ent`;
- `entidad`;
- `cve_mun`;
- `municipio`.

No se incorporó localidad, latitud ni longitud, porque la llave validada identifica entidad y municipio, no una localidad exacta del hogar.

Estratificación territorial

Las clasificaciones territoriales actuales son:

- `region_banxico`: Norte, Centro Norte, Centro y Sur, construida desde `cve_ent`;
- `entidad`: nivel defendible para resultados ENIGH;
- `tam_loc_desc`: tamaño de localidad como aproximación oficial de urbanización/ruralidad;
- `est_socio_desc`: estrato socioeconómico oficial de INEGI;
- `municipio`: solo exploratorio/contextual, con cautela de representatividad.

No se creó una regionalización propia ni clustering territorial. La decisión actual es usar primero clasificaciones oficiales o institucionales.

Estado del arte

En el documento `reports/estado_del_arte_geografia_ingresos_ENIGH.md` se identifican tres referencias principales:

- INEGI: diseño muestral estratificado, tamaño de localidad, estrato socioeconómico, factor, `est_dis` y `upm`.
- Banco de México: regiones económicas y análisis regional de Gini/fuentes de ingreso con ENIGH.
- CONAPO: índices de marginación como posible enriquecimiento futuro.

Banco de México reporta Gini regional aproximado para 2018, 2020 y 2022. La tabla documentada usa valores en escala 0-100: Nacional 45.7, 45.0 y 43.1; Sur muestra la desigualdad más alta entre regiones. El recuadro metodológico indica que el benchmark usa ingreso corriente total promedio por hogar, por lo que la comparación del notebook 09 usa `ing_cor_hogar_oficial_tri`, no el ingreso per cápita.

Diferenciación del proyecto

El valor potencial del proyecto no está en repetir que hay diferencias regionales de ingreso o Gini. La aportación más defendible es estudiar:

```
determinantes del ingreso
× territorio
× tiempo
```

Es decir: cómo cambian las asociaciones entre ingreso y educación, sexo, edad, características laborales, composición del hogar y estratos territoriales entre 2018 y 2024.

EDA y análisis regional hasta notebook 07

El notebook `07_analisis_regional_ingresos.ipynb` usa como target central `ingreso_persona_laboral_negocio_tri` y separa la submuestra con ingreso laboral positivo para evitar que las medianas queden dominadas por personas sin ingreso laboral.

Hallazgos descriptivos preliminares del notebook 07:

- personas con ingreso laboral positivo: 574,462, equivalentes a 47.7% de la base de personas;
- mediana trimestral muestral de ingreso laboral: Norte \$22,131 y Sur \$11,739;
- ingreso corriente per cápita del hogar, mediana muestral: Norte \$16,713 y Sur \$10,477;
- localidades de 100,000 o más habitantes tienen mediana laboral muestral \$22,500 frente a \$13,011 en localidades menores de 2,500 habitantes;
- estrato Alto registra mediana laboral muestral \$33,359 y Bajo \$10,125;
- mediana laboral muestral por sexo: hombres \$19,392; mujeres \$12,984;
- mediana laboral muestral por contrato: con contrato \$28,124; sin contrato \$14,478.

Estos resultados son descriptivos, nominales y no ponderados. No deben leerse como estimaciones poblacionales hasta recalcular su versión ponderada con el factor adecuado.

Calidad, faltantes y ceros hasta notebook 08

El notebook `08_calidad_bases_analiticas.ipynb` audita faltantes, ceros y universos aplicables. La documentación técnica detallada queda en `reports/calidad_faltantes_y_ceros.md`.

Conclusiones principales:

- las variables geográficas, estratos y diseño muestral prioritarias están completas;
- los targets monetarios principales no tienen faltantes;
- los faltantes grandes en variables laborales son estructurales por universo;
- `edo_conyug_desc` falta por edad 0-11 y queda completo en 12+;
- `nivelaprob_desc` falta principalmente en edades 0-5;
- `nivel_desc` no es escolaridad general, sino nivel educativo actual de quienes asisten a la escuela;
- los ceros de ingreso laboral se conservan como valores sustantivos/estructurales;
- no se imputa.

Correcciones cerradas antes de avanzar:

- `asis_esc_desc`: corregida por código oficial `asis_esc` (1 = Sí, 2 = No).
- `personas_con_registros_ingreso`: 250 NaN validados contra `mart_persona` y convertidos a 0 porque no había registros individuales en `ingresos.csv`.

Poblaciones analíticas

Universo	2018	2020	2022	2024	Total
Base completa de personas	269,206	315,743	309,684	308,598	1,203,231

Universo	2018	2020	2022	2024	Total
Personas con trabajo reportado	127,638	149,387	150,682	150,382	578,089
Personas con ingreso laboral positivo	127,846	148,082	149,569	148,965	574,462
Hogares	74,647	89,006	90,102	91,414	345,169

Para ingreso laboral se recomienda separar:

- probabilidad de tener ingreso laboral positivo;
- monto del ingreso condicionado a ingreso laboral positivo.

Diseño muestral

Las bases conservan `factor`, `factor_hogar`, `est_dis` y `upm`. En esta etapa se usan para estimaciones descriptivas puntuales, no para inferencia formal.

`factor` permite expandir la muestra a la población representada. Para errores estándar, intervalos de confianza o pruebas inferenciales todavía será necesario incorporar el diseño complejo con `factor`, `est_dis` y `upm`.

Factor de expansión

Auditoría metodológica agregada el 2026-08-31 antes de continuar con deflactación, diseño muestral formal o modelos. El principio permanente queda así: antes de reportar media, mediana, cuantiles, Gini, proporciones o brechas se debe registrar unidad de observación, población objetivo, variable de peso y definición del estimando.

Evidencia oficial INEGI revisada en los PDF locales `data/raw/EINGH/<año>/doc_<año>.pdf`, sección 1.3.3:

- 2018 y 2020: el factor de expansión para cualquier nivel se encuentra en `factor` de VIVIENDAS y CONCENTRADOHOGAR; `poblacion.csv` no trae `factor` directo.
- 2022 y 2024: el factor de expansión para cualquier nivel se encuentra en `factor` de VIVIENDAS, HOGARES, POBLACION, GASTOSHOGAR, GASTOSPERSONA, INGRESOS, TRABAJOS y CONCENTRADOHOGAR.
- En las tablas raw donde aparece `factor`, no se detectaron diferencias contra CONCENTRADOHOGAR por las llaves disponibles.
- En `mart_persona`, cada fila ya representa una persona y debe ponderarse con `factor`; no se debe multiplicar de nuevo por `tot_integ`.

Tabla definitiva de ponderación:

Estimando	Unidad de la tabla	Peso	Interpretación
Media ingreso hogar	Hogar	<code>factor</code>	Hogares
Mediana ingreso hogar	Hogar	<code>factor</code>	Hogares
Media ingreso individual	Persona	<code>factor</code>	Personas

Estimando	Unidad de la tabla	Peso	Interpretación
Mediana ingreso individual	Persona	factor	Personas
Población total desde hogares	Hogar	factor × tot_integ	Personas integrantes del hogar
Ingreso PC hogar distribuido entre hogares	Hogar	factor	Hogares
Ingreso PC hogar distribuido entre personas	Hogar	factor × tot_integ	Personas integrantes del hogar
Ingreso PC hogar distribuido entre personas desde mart_persona	Persona	factor	Personas

Prueba de doble ponderación sobre filas persona:

Año	sum(factor) en mart_persona	sum(factor × tot_integ) sobre mart_persona	Razón
2018	123,934,029	561,257,240	4.53
2020	126,838,467	566,104,426	4.46
2022	128,999,038	558,856,484	4.33
2024	130,325,969	554,726,112	4.26

Esto demuestra que factor × tot_integ no puede usarse sobre filas que ya son personas.

Para ingreso corriente per cápita del hogar, el estimando principal del análisis territorial queda definido como distribución **entre personas**: una fila por persona en mart_persona, valor ing_cor_hogar_pc_oficial_tri, peso factor. El cálculo desde hogares con factor × tot_integ se conserva solo como contraste conceptual. La equivalencia no es exacta porque la suma de factor en mart_persona difiere ligeramente de factor × tot_integ desde hogares, pero las diferencias de mediana son pequeñas.

Año	Mediana hogar × integrantes	Mediana mart_persona	Diferencia	Gini hogar × integrantes	Gini mart_persona	Diferencia
2018	9,294.44	9,297.60	3.16	46.01	46.29	0.28
2020	9,710.88	9,717.91	7.03	44.95	45.05	0.09
2022	12,979.34	12,989.18	9.84	43.70	44.04	0.34
2024	16,596.64	16,602.02	5.38	42.87	43.05	0.18

Media ponderada:

$$\bar{x}_w = \frac{\sum_i w_i x_i}{\sum_i w_i}$$

Mediana ponderada:

1. Ordenar las observaciones por valor.
2. Acumular los pesos.
3. Identificar el punto donde se alcanza 50% del peso acumulado.

Cuantiles ponderados: la misma lógica se usa para P25, P75, P90, P95 y P99.

Gini ponderado: la distribución considera la frecuencia poblacional representada por cada peso. En el notebook se conservan ceros y se excluyen solo valores faltantes, negativos o pesos no positivos.

Resumen de expansión:

Año	Hogares muestrales	Hogares expandidos	Personas desde hogares	Personas desde mart_persona
2018	74,647	34,400,515	123,836,081	123,934,029
2020	89,006	35,749,659	126,760,856	126,838,467
2022	90,102	37,560,123	128,889,708	128,999,038
2024	91,414	38,830,230	130,226,218	130,325,969

El diseño complejo se mantiene separado: factor + est_dis + upm será necesario para errores estándar, intervalos de confianza y pruebas inferenciales. En esta etapa solo se reportan estimaciones descriptivas puntuales.

Índice Gini

Benchmark: [Banco de México, Cuadro 2 del Reporte sobre las Economías Regionales enero-marzo 2024](#). El recuadro reporta Gini 2018, 2020 y 2022 por región y nacional, con bases generadas por CONEVAL a partir de ENIGH.

Para calcular el índice de Gini se utiliza la siguiente fórmula:

$$G = 1 - \sum_{i=1}^{n-1} (X_{i+1} - X_i)(Y_{i+1} + Y_i)$$

Donde:

- G : índice de Gini.
- X_i : proporción acumulada de la población hasta la observación i .
- Y_i : proporción acumulada del ingreso hasta la observación i .
- n : número total de observaciones o grupos considerados.

Escala de valores:


- 0 o 0%: Representa la igualdad perfecta. Significa que todas las personas de la población tienen exactamente los mismos ingresos
- 1 o 100%: Representa la desigualdad máxima. Significa que una sola persona concentra la totalidad de los ingresos y el resto no recibe nada.

Niveles de referencia prácticos

- **Menor a 0.3:** Indica una sociedad con una distribución de ingresos muy igualitaria (común en algunos países nórdicos o europeos).
- **Entre 0.3 y 0.4:** Señala una igualdad aceptable, aunque ya existe cierta concentración de la riqueza.
- **Mayor a 0.4:** Representa un punto de alerta o crítico de desigualdad significativa, el cual suele asociarse con mayores tensiones sociales.
- **Valores superiores a 0.5** son comunes en regiones con brechas muy pronunciadas, como en algunas zonas de América Latina.

Referencia: <https://www.esic.edu/rethink/business/indice-de-gini-que-es-y-como-se-calcula-c>

Ejemplo gráfico



Referencia: <https://saludyeducacion2.blogspot.com/2018/02/el-coeficiente-de-gini-y-sus.html>

Definición primaria usada en el notebook 09:

- variable: `ing_cor_hogar_oficial_tri`, equivalente en el mart a `ing_cor` de `concentradohogar`;
- ponderador: `factor`;
- universo: hogares con ingreso no faltante, ingreso no negativo y factor positivo;
- unidad: hogar;
- escala: Gini en 0-100

Gini nacional propio:

Año	Gini ponderado
2018	43.83
2020	42.60
2022	41.27
2024	40.06

Comparación mart vs **concentradohogar** directo:

Año	Gini mart	Gini concentradohogar	Diferencia
2018	43.8299	43.8299	0.0000
2020	42.5978	42.5978	0.0000
2022	41.2677	41.2677	0.0000
2024	40.0624	40.0624	0.0000


La construcción del mart no explica la discrepancia con Banxico.

Comparación ponderado vs no ponderado, nacional:

Año	Gini ponderado	Gini no ponderado	Banxico
2018	43.83	42.73	45.70
2020	42.60	42.05	45.00
2022	41.27	40.95	43.10


Diagnóstico de definición:

- El cálculo hogar-total ponderado por **factor** queda sistemáticamente por debajo de Banxico.
- La discrepancia máxima con esa definición es 3.22 puntos de Gini en Sur 2020.
- Una variante diagnóstica con ingreso per cápita distribuido entre personas, calculada desde **mart_persona** con **factor**, se acerca más: discrepancia máxima aproximada de 1.71 puntos.
- Esto sugiere que la diferencia más probable no está en el mart ni en la ausencia de ponderación, sino en la definición exacta de ingreso/unidad de distribución usada por las bases CONEVAL/Banxico.
- No se fuerza la coincidencia: hasta reproducir exactamente la construcción CONEVAL, la validación se clasifica como reproducción parcial.



La variante per cápita es diagnóstica; no reemplaza la definición primaria sin validar CONEVAL.


Fuente: elaboración propia con ENIGH 2018-2022 y benchmark Banco de México. Estadísticos ponderados; la línea per cápita es diagnóstica. Montos nominales trimestrales.




Fuente: elaboración propia con ENIGH 2018-2024. Gini ponderado con **factor**, ingreso corriente total del hogar, universo de hogares.

y brecha territorial


La desigualdad interna mide dispersión dentro de un territorio: Gini, P90/P10 y P75/P25. La brecha territorial mide distancia entre territorios: diferencia de medianas, razón de medianas o diferencia de ingreso per cápita.



Fuente: elaboración propia con ENIGH 2024. Ingreso corriente per cápita del hogar distribuido entre personas: `mart_persona + factor`. Montos nominales trimestrales.



Fuente: elaboración propia con ENIGH 2024. Mediana ponderada del ingreso corriente per cápita del hogar distribuido entre personas: `mart_persona + factor`. Montos nominales trimestrales.



Fuente: elaboración propia con ENIGH 2024. Mediana ponderada del ingreso corriente per cápita del hogar distribuido entre personas: `mart_persona` + `factor`. Montos nominales trimestrales.

Guadalajara Monterrey y CDMX

Fuente oficial: [CONAPO/SEDATU/INEGI, Las metrópolis de México 2020](#), recurso “Características poblacionales por municipio”. Se construyó `docs/zonas_metropolitanas_prioritarias_2020.csv` con las tres zonas requeridas.

La fuente nombra la zona como “Ciudad de México”; en el proyecto se reporta como “Valle de México”, conservando `nombre_oficial` en el mapping. La delimitación incluye:

Zona	Municipios oficiales	Entidades incluidas
Valle de México	63	Ciudad de México, Hidalgo, México
Guadalajara	7	Jalisco
Monterrey	16	Nuevo León

Cobertura ENIGH 2024:


Zona	Hogares	Personas	Población expandida	Municipios presentes	UPM- diseño
Valle de México	4,540	14,755	22,419,780	50	735

Zona	Hogares	Personas	Población expandida	Municipios presentes	UPM- diseño
Guadalajara	1,373	4,487	6,021,378	7	277
Monterrey	2,509	8,264	5,743,578	15	419

La cobertura es razonable para una comparación descriptiva agregada, pero no equivale a inferencia formal con diseño complejo.

CDMX no es equivalente a la Zona Metropolitana del Valle de México:

Métrica 2024	n muestral	Población expandida	Mediana ponderada	Gini ponderado
CDMX entidad: ingreso corriente hogar	2,576	3,082,330	\$81,866	40.40
CDMX entidad: ingreso corriente per cápita entre personas	8,182	9,381,255	\$23,987	46.23
ZM Valle de México: ingreso corriente per cápita entre personas	14,755	22,419,780	\$19,705	43.84
CDMX entidad: ingreso laboral individual positivo	4,285	4,903,427	\$28,673	48.67




Fuente: elaboración propia con ENIGH 2024. Mediana ponderada del ingreso corriente per cápita del hogar distribuido entre personas: `mart_persona` + `factor`. Montos nominales trimestrales.

Comparación 2024 de grandes zonas metropolitanas y contexto desfavorecido:

Grupo	n muestral	Población expandida	Mediana ponderada	Gini	P90/P10
Monterrey	8,264	5,743,578	\$24,911	45.35	5.72

Grupo	n muestral	Población expandida	Mediana ponderada	Gini	P90/P10
Guadalajara	4,487	6,021,378	\$21,078	39.31	5.22
Valle de México	14,755	22,419,780	\$19,705	43.84	6.35
Localidad pequeña y estrato socioeconómico bajo	50,657	13,981,703	\$7,888	39.45	6.13

El grupo desfavorecido es descriptivo, no una clasificación de marginación: se define con `tam_loc_desc = Localidades con menos de 2 500 habitantes` y `est_socio_desc = Bajo`. La razón de medianas entre Monterrey y este grupo es 3.16 en 2024, ahora medida como ingreso per cápita distribuido entre personas.



Fuente: elaboración propia con ENIGH 2024. Mediana ponderada del ingreso corriente per cápita del hogar distribuido entre personas: `mart_persona + factor`. Montos nominales trimestrales.

Deflactores de ingresos

Etapla agregada el 2026-08-31. A partir de esta sección, las comparaciones temporales de niveles monetarios entre 2018, 2020, 2022 y 2024 se reportan como montos reales en pesos de 2024. Los montos nominales originales se conservan en paralelo para contraste y sensibilidad.

Fuentes oficiales revisadas:

- [INEGI, ENIGH 2024, página del programa](#): confirma objetivo, unidad de observación, ponderador `factor`, cobertura, diseño y periodo de levantamiento.
- [INEGI, ENIGH 2024, presentación de resultados](#): publica el ingreso corriente promedio trimestral del hogar 2016-2024 en pesos de 2024.
- [INEGI, ENIGH 2024, diseño conceptual](#): define ingreso corriente, componentes y periodos de referencia.
- [INEGI, INPC 2024](#): confirma el INPC como indicador oficial de inflación, con base segunda quincena de julio de 2018 = 100 y actualización 2024.
- [CONEVAL, líneas de pobreza por ingresos](#): referencia institucional de actualización mensual de valores monetarios con el INPC publicado por INEGI.

La metodología ideal sería reconstruir deflactores mensuales por periodo de referencia y componente de ingreso cuando la documentación y microdatos conserven ese nivel de detalle. En los marts actuales, las variables de ingreso están agregadas a nivel hogar/persona y no preservan el mes exacto por fuente de ingreso. Por ello se usa una aproximación explícita, reproducible y validada contra INEGI: un **deflactor_2024** común por año, calibrado al benchmark oficial del ingreso corriente promedio trimestral del hogar.

Fórmula aplicada:

```
deflactor_2024_año = benchmark_inegi_ingreso_corriente_hogar_pesos_2024_año /  
promedio_nominal_ponderado_mart_hogar_año  
monto_real_2024 = monto_nominal * deflactor_2024_año
```

Para 2024 se fija **deflactor_2024 = 1.0**, por lo que las variables nominales y reales coinciden en ese año salvo redondeo de publicación. Esta decisión también evita confundir **factor**, que es ponderador muestral, con el ajuste monetario.

Tabla versionable de deflactores: docs/deflactores_precios_2024.csv.

Año	Promedio nominal ponderado mart	Benchmark INEGI pesos 2024	deflactor_2024
2018	\$49,851	\$67,319	1.350404
2020	\$50,309	\$63,400	1.260204
2022	\$63,695	\$70,391	1.105118
2024	\$77,864	\$77,864	1.000000

Validación externa contra INEGI:

Año	Nuestro promedio real	INEGI	Diferencia absoluta	Diferencia %	Conclusión
2018	\$67,319	\$67,319	\$0	0.0%	reproducción cercana
2020	\$63,400	\$63,400	\$0	-0.0%	reproducción cercana
2022	\$70,391	\$70,391	\$0	0.0%	reproducción cercana
2024	\$77,864	\$77,864	\$0	-0.0%	reproducción cercana

La mayor diferencia es de \$0.16 en 2024, equivalente a -0.0002%, atribuible a redondeo porque el deflactor de 2024 se fija en 1.0. La reproducción se clasifica como cercana.

Validación de Gini:

Año	Gini nominal	Gini real 2024	Diferencia
2018	43.8299	43.8299	0.00000000
2020	42.5978	42.5978	0.00000000
2022	41.2677	41.2677	0.00000000
2024	40.0624	40.0624	0.00000000

Como el deflactor es común dentro de cada año, el Gini no cambia. Esta propiedad no se asumiría si en una etapa posterior se reconstruyeran deflactores mensuales por observación o por componente.

Variables reales creadas:

- `mart_hogar`: 16 variables monetarias con sufijo `_real_2024`.
- `mart_persona`: 17 variables monetarias con sufijo `_real_2024`.
- Ambas bases agregan `deflactor_2024` como metadata de conversión.

Los nuevos marts locales quedaron en `data/interim/revision_5/`:

- `mart_hogar_2018_2024.csv.gz`: 345,169 filas.
- `mart_persona_2018_2024.csv.gz`: 1,203,231 filas.

`revision_4` permanece intacta y `data/raw/` no se modificó.

Impacto de la homologación monetaria:

Indicador	Periodo	Cambio nominal	Cambio real	Diferencia pp
Media ingreso corriente hogar	2018-2024	56.2%	15.7%	-40.5 pp
Mediana ingreso corriente hogar	2018-2024	66.1%	23.0%	-43.1 pp
Mediana ingreso corriente per cápita	2018-2024	78.6%	32.2%	-46.3 pp
Mediana ingreso laboral individual positivo	2018-2024	69.7%	25.6%	-44.0 pp
Brecha Norte-Sur	2018-2024	93.6%	43.4%	-50.2 pp
Brecha urbano-rural	2018-2024	80.1%	33.4%	-46.7 pp
Brecha estrato Alto-Bajo	2018-2024	64.0%	21.5%	-42.6 pp

La lectura principal cambia: por ejemplo, la mediana ponderada del ingreso corriente del hogar parece crecer 66.1% nominal entre 2018 y 2024, pero el crecimiento real es 23.0%. En 2020 se observa una caída real

respecto a 2018; se documenta como observación descriptiva de una edición levantada durante el periodo de pandemia COVID-19, sin atribución causal.

Evolución real nacional del ingreso corriente del hogar:

Año	Media real	P25	Mediana real	P75	P90
2018	\$67,319	\$29,021	\$48,139	\$79,472	\$128,381
2020	\$63,400	\$28,108	\$46,154	\$76,068	\$121,114
2022	\$70,391	\$32,271	\$52,304	\$84,383	\$132,591
2024	\$77,864	\$36,875	\$59,218	\$95,142	\$145,809

Resultados por región Banxico, usando ingreso corriente per cápita del hogar distribuido entre personas (**mart_persona** + **factor**):

Región	Mediana 2018 real	Mediana 2024 real	Variación 2018-2024
Norte	\$15,824	\$22,269	40.7%
Centro Norte	\$13,525	\$17,585	30.0%
Centro	\$12,873	\$16,485	28.1%
Sur	\$8,674	\$12,019	38.6%

Brecha Norte-Sur real:

Año	Mediana Norte	Mediana Sur	Diferencia real	Razón
2018	\$15,824	\$8,674	\$7,150	1.82
2020	\$16,145	\$8,836	\$7,308	1.83
2022	\$19,783	\$10,508	\$9,276	1.88
2024	\$22,269	\$12,019	\$10,250	1.85

Tamaño de localidad:

Año	Mediana 100,000+	Mediana <2,500	Diferencia real	Razón
2018	\$16,519	\$7,886	\$8,633	2.09
2020	\$15,677	\$8,183	\$7,493	1.92
2022	\$18,694	\$9,643	\$9,051	1.94
2024	\$21,841	\$10,326	\$11,515	2.12

Estrato socioeconómico:

Año	Mediana Alto	Mediana Bajo	Diferencia real	Razón
2018	\$30,532	\$6,752	\$23,780	4.52
2020	\$26,745	\$7,048	\$19,697	3.79
2022	\$30,984	\$8,375	\$22,609	3.70
2024	\$38,042	\$9,157	\$28,885	4.15

CDMX y metrópolis:

- CDMX entidad, ingreso corriente per cápita real entre personas: mediana 2024 \$23,987, P25 \$14,820, P75 \$40,987, P90 \$77,707, Gini 46.23.
- Valle de México: mediana real 2018 \$15,828 y 2024 \$19,705, variación 24.5%.
- Guadalajara: mediana real 2018 \$16,982 y 2024 \$21,078, variación 24.1%.
- Monterrey: mediana real 2018 \$18,265 y 2024 \$24,911, variación 36.4%.

Brecha metropolitana real 2024:

Territorio	n muestral	Mediana real	P25	P75	P90/P10	Gini
Monterrey	8264	\$24,911	\$16,233	\$39,539	5.73	45.35
Guadalajara	4487	\$21,078	\$13,893	\$32,468	5.22	39.31
Valle de México	14755	\$19,705	\$13,033	\$32,218	6.35	43.84
Localidad pequeña y estrato socioeconómico bajo	50657	\$7,888	\$4,888	\$12,355	6.13	39.45


Ingreso laboral individual positivo:

Año	Mediana real	P25	P75	P90
2018	\$19,287	\$8,192	\$32,300	\$54,414
2020	\$17,849	\$7,089	\$30,820	\$51,408
2022	\$21,081	\$10,135	\$34,460	\$56,217
2024	\$24,231	\$11,984	\$38,852	\$61,598


Brecha descriptiva no ajustada por sexo:

Año	Hombres	Mujeres	Diferencia real	Razón H/M
2018	\$22,194	\$14,644	\$7,549	1.52
2020	\$20,452	\$13,869	\$6,583	1.47
2022	\$24,216	\$16,865	\$7,351	1.44
2024	\$27,391	\$19,957	\$7,435	1.37

Figuras principales:




Fuente: elaboración propia con ENIGH 2018-2024 e INEGI ENIGH 2024 como benchmark. Universo: hogares. Ponderador: **factor**. Montos reales en pesos de 2024. Unidad temporal: ingreso trimestral.




Fuente: elaboración propia con ENIGH 2018-2024. Universo: personas. Ponderador: **factor**. Variable: ingreso corriente per cápita del hogar distribuido entre personas. Montos reales en pesos de 2024. Unidad temporal:


ingreso trimestral.




Fuente: elaboración propia con ENIGH 2018-2024. Universo: personas. Ponderador: **factor**. Variable: ingreso corriente per cápita del hogar distribuido entre personas. Montos reales en pesos de 2024. Unidad temporal: ingreso trimestral.



Fuente: elaboración propia con ENIGH 2018-2024. Universo: personas. Ponderador: **factor**. Categorías oficiales de tamaño de localidad. Montos reales en pesos de 2024. Unidad temporal: ingreso trimestral.




Fuente: elaboración propia con ENIGH 2018-2024. Universo: personas. Ponderador: **factor**. Variable oficial **est_socio_desc**. Montos reales en pesos de 2024. Unidad temporal: ingreso trimestral.



Fuente: elaboración propia con ENIGH 2018-2024 y delimitación CONAPO/SEDATU/INEGI 2020 ya validada. Universo: personas. Ponderador: **factor**. Variable: ingreso corriente per cápita del hogar distribuido entre personas. Montos reales en pesos de 2024. Unidad temporal: ingreso trimestral.

Flujo metodológico:




Decisión para modelos futuros:


Los modelos cuyo objetivo sea comparar niveles monetarios a través del tiempo utilizarán como especificación principal ingresos expresados en pesos constantes de 2024. Se conservará una especificación equivalente utilizando ingresos nominales para evaluar la sensibilidad de los resultados a la homologación monetaria.

Esta comparación permitirá estudiar cambios en coeficientes, efectos temporales, interacciones con año, estabilidad de signos, estabilidad de significancia y capacidad explicativa. En modelos logarítmicos deberá verificarse posteriormente que, si el deflactor es constante dentro de cada año y el modelo incluye efectos fijos de año, la homologación equivale a sumar una constante específica del año al logaritmo del ingreso; esto puede dejar casi intactos algunos efectos transversales y cambiar principalmente interceptos, efectos de año e interpretación temporal.


Flujo de datos:




Construcción de bases analíticas:




Ponderación y diseño:



Flujo de análisis de faltantes:



Desigualdad vs brecha:



Roadmap

Etapa	Estado
08 Calidad de bases	COMPLETO
09 Desigualdad territorial	COMPLETO: ponderación auditada, Gini nacional/regional, validación Banxico, CDMX, zonas metropolitanas, brechas territoriales, unidad del estimando documentada
10 Homologación monetaria	COMPLETO: nominal preservado, real 2024 construido, impacto nominal vs real documentado
11 Diseño muestral formal	SIGUIENTE
12 Determinantes del ingreso	Pendiente: modelo principal real y contraste nominal
13 Heterogeneidad territorial	Pendiente: especificación real y sensibilidad nominal
14 Descomposición de desigualdad	Pendiente
15 Robustez y sensibilidad	Pendiente: nominal vs real, con/sin est_socio , universos alternativos, 2020 y especificaciones alternativas
16 Resultados y conclusiones	Pendiente

Comentarios generales

- Los años son cortes transversales, no panel.
- Las comparaciones temporales centrales ya cuentan con variables reales en pesos de 2024 en `revision_5`; los nominales se conservan como referencia y sensibilidad.
- La homologación monetaria actual usa un `deflactor_2024` común por año calibrado al benchmark oficial de INEGI; no reproduce deflatores mensuales por componente porque esa granularidad no está en los marts actuales.
- El Gini dentro de un año no cambia si todos los ingresos se multiplican por el mismo `deflactor_2024`, pero comparaciones reales de niveles, diferencias absolutas y crecimiento temporal deben usar variables `_real_2024`.
- `factor` permite estimaciones puntuales ponderadas; no sustituye el diseño muestral completo para inferencia.
- Los municipios y zonas metropolitanas se usan como agregados descriptivos; no se reportan como dominios inferenciales formales.
- No se incorporó marginación CONAPO en esta etapa.
- No se construyó una variable definitiva de formalidad laboral.
- Las asociaciones observadas no deben interpretarse como causalidad.
- Los agregados derivados desde `ingresos.csv` no sustituyen automáticamente las variables oficiales de `concentradohogar`.

Siguientes pasos

- Antes de reportar cualquier estadístico ponderado, registrar: unidad de observación, población objetivo, variable de peso y definición del estimando.
- No inventar resultados: todo valor reportado debe salir de notebooks o documentación revisada.
- No asumir causalidad desde asociaciones descriptivas.
- No usar municipios como dominios representativos sin revisión de diseño y muestra.
- No convertir faltantes a cero sin validar universo o llave.
- Separar ceros legítimos, ceros estructurales y códigos con valor 0.
- Priorizar interpretabilidad, visualización y reproducibilidad.
- Mantener documentación viva en este archivo y detalle técnico de calidad en `reports/calidad_faltantes_y_ceros.md`.
- Los modelos que comparen niveles monetarios a través del tiempo usarán ingresos reales 2024 como especificación principal y conservarán ingresos nominales como sensibilidad.